

Analisis Sentimen Multitugas Komentar Instagram pada Kasus Dugaan Korupsi Pengadaan Chromebook Menggunakan IndoBERT

Multi-task Sentiment Analysis of Instagram Comments on the Alleged Chromebook Procurement Corruption Case Using IndoBERT

Mohammad Farid Hendianto

Program Studi Informatika, Fakultas Teknologi Industri, Universitas Ahmad Dahlan
Jl. Ringroad Selatan, Kragilan, Tamanan, Banguntapan, Bantul, Daerah Istimewa Yogyakarta, Indonesia
NIM 2200018401 | e-mail: hendik.suwoto@gmail.com

Abstrak

Kasus dugaan korupsi pengadaan Chromebook yang menyeret Nadiem Makarim menimbulkan reaksi publik yang besar di media sosial. Reaksi tersebut tersebar ke banyak pihak dan bercampur dengan berbagai emosi sehingga sulit dipahami hanya melalui pembacaan manual. Penelitian ini menganalisis sentimen 38.845 komentar Instagram dari sebelas unggahan yang membahas kasus tersebut. Data mentah dibersihkan melalui prapemrosesan yang mencakup normalisasi Unicode, perapihan spasi, dan pengelompokan komentar *near-duplicate* untuk mencegah kebocoran data. Pelabelan disusun dalam tiga lapis, yaitu *spam*, sikap dengan enam kelas, dan emosi dengan lima kelas. Sebanyak 710 komentar dilabeli manusia sebagai acuan uji dan 5.912 komentar dilabeli *Large Language Model* (LLM) lokal sebagai data latih tambahan. Model utama adalah IndoBERT multitugas dengan satu *encoder* dan tiga lapisan klasifikasi (*classification head*), yang dibandingkan dengan *baseline* TF-IDF dan regresi logistik. Evaluasi menggunakan *macro-F1* pada data uji berlabel manusia. Hasil menunjukkan IndoBERT multitugas memperoleh *macro-F1* sebesar 0,544 pada tugas sikap dan 0,624 pada tugas emosi, sedikit di atas *baseline* TF-IDF yang memperoleh 0,534 dan 0,616. Analisis komposisi memperlihatkan kritik terhadap lembaga peradilan cukup menonjol sebesar 22,8 persen dan meningkat menjadi 27,3 persen pada fase vonis, sedangkan emosi yang paling banyak muncul adalah duka dan marah. Data berasal dari sebelas unggahan sehingga hasilnya tidak dapat digeneralisasi sebagai opini publik nasional.

Kata kunci: analisis sentimen; IndoBERT; pembelajaran multitugas; komentar Instagram; *macro-F1*

Abstract

The alleged Chromebook procurement corruption case involving Nadiem Makarim triggered a large public reaction on social media. The reaction was directed at many parties and mixed with various emotions, making it difficult to understand through manual reading alone. This study analyzes the sentiment of 38,845 Instagram comments from eleven posts discussing the case. The raw data were cleaned through preprocessing that includes Unicode normalization, whitespace tidying, and near-duplicate clustering to prevent data leakage. The labels were arranged in three layers, namely spam, stance with six classes, and emotion with five classes. A total of 710 comments were labeled by humans as the test reference and 5,912 comments were labeled by a local large language model as additional training data. The main model is a multi-task IndoBERT with one encoder and three classification heads, compared with a TF-IDF and logistic regression baseline. Evaluation uses macro-F1 on the human-labeled test set. The results show that multi-task IndoBERT obtains a macro-F1 of 0.544 on the stance task and 0.624 on the emotion task, slightly above the TF-IDF baseline which obtains 0.534 and 0.616. Composition analysis shows that criticism of the judiciary is fairly prominent at 22.8 percent and increases to 27.3 percent in the verdict phase, while the most frequent emotions are sadness and anger. The data come from eleven posts, so the results cannot be generalized as national public opinion.

Keywords: sentiment analysis; IndoBERT; multi-task learning; Instagram comments; macro-F1

1. Pendahuluan

Media sosial telah menjadi ruang utama masyarakat untuk menyampaikan pendapat terhadap isu hukum dan kebijakan publik. Ketika Nadiem Makarim terseret dalam kasus dugaan korupsi pengadaan Chromebook untuk sekolah, kolom komentar di berbagai unggahan Instagram dipenuhi tanggapan warganet dalam jumlah besar dan dengan ragam sikap yang luas. Tanggapan tersebut tidak hanya berbicara

tentang sosok yang bersangkutan, tetapi juga menyoroti proses peradilan, pemerintah, dan kebijakan pendidikan. Volume dan keragaman seperti ini menyulitkan pembacaan manual, sehingga diperlukan pendekatan otomatis untuk memetakan sentimen komentar secara sistematis.

Analisis sentimen berbahasa Indonesia sudah banyak diterapkan pada beragam topik. Putranti dan Winarko mengklasifikasikan sentimen

Twitter berbahasa Indonesia menggunakan Maximum Entropy dan Support Vector Machine (SVM) [1]. Fitriyah dkk. menganalisis sentimen layanan Gojek di Twitter dengan SVM dan memperoleh akurasi sekitar 79 persen [2], sementara Sinulingga dan Sitorus mengombinasikan SVM dengan pembobotan TF-IDF pada ulasan film horor dan mencapai akurasi 82,51 persen [3]. Pada ranah kebijakan publik, Setiawan dan Suryono membandingkan SVM dan Naive Bayes untuk sentimen pemindahan Ibu Kota Nusantara [4], Pramudita dkk. menerapkan Naive Bayes pada program Kartu Indonesia Pintar Kuliah [5], dan Khadapi serta Pakpahan membandingkan LSTM dan BERT pada diskusi Pemilu 2024 [6]. Secara khusus, Putri dkk. menganalisis sentimen publik terhadap Nadiem Makarim sebagai Mendikbudristek menggunakan SVM dengan TF-IDF [7]. Sebagian besar studi tersebut memakai skema dua atau tiga kelas, yaitu positif, negatif, dan netral, terhadap satu target tunggal.

Metode klasik seperti SVM dan Naive Bayes mudah diinterpretasikan dan ringan, tetapi kurang menangkap konteks kata pada kalimat yang panjang, sarkasme, dan campur bahasa. Model berbasis Transformer mengatasi keterbatasan itu melalui mekanisme perhatian yang memodelkan hubungan antarkata [8], [9]. Untuk bahasa Indonesia telah tersedia IndoBERT, model pralatih yang dilatih pada korpus besar dan memberi peningkatan kinerja pada banyak tugas pemrosesan bahasa alami [10], [11]. Pemanfaatan model pralatih dan representasi kontekstual juga terbukti meningkatkan analisis sentimen berbahasa Indonesia dibanding pendekatan berbasis fitur klasik [12]. Selain itu, pembelajaran multitugas memungkinkan satu model belajar beberapa tugas terkait secara bersamaan sehingga representasinya saling menguatkan dan ukuran model tetap ringkas [13].


Berdasarkan penelusuran tersebut, terdapat beberapa celah yang menjadi perhatian

penelitian ini. Pertama, sebagian besar studi memperlakukan sentimen sebagai polaritas tunggal terhadap satu objek, padahal wacana kasus ini terarah ke banyak pihak sekaligus, yaitu Nadiem, lembaga peradilan, dan pemerintah, serta memuat dimensi emosi yang berbeda dari sikap. Kedua, ketidakseimbangan kelas dan komentar *near-duplicate* yang berpotensi menimbulkan kebocoran antara data latih dan data uji jarang ditangani secara eksplisit. Ketiga, evaluasi sering hanya melaporkan akurasi yang bias pada kelas mayoritas.

Penelitian ini mengusulkan analisis sentimen multitugas atas komentar Instagram pada kasus pengadaan Chromebook. Model IndoBERT multitugas dengan satu *encoder* dan tiga lapisan klasifikasi (*classification head*) digunakan untuk memprediksi *spam*, sikap, dan emosi secara serentak, lalu dibandingkan dengan *baseline* TF-IDF dan regresi logistik. Kontribusi penelitian ini adalah pipeline data yang menangani teks kotor dan *near-duplicate*, skema label tiga lapis yang mengakui banyaknya target wacana, serta evaluasi yang jujur menggunakan *macro-F1* pada data uji berlabel manusia. Tujuannya adalah memetakan sikap dan emosi komentar sepanjang perkembangan kasus, sekaligus menguji sejauh mana model pralatih mengungguli *baseline* klasik pada data yang terbatas.

2. Metode Penelitian

Penelitian ini menggunakan pendekatan kuantitatif dengan tahapan yang ditunjukkan pada Gambar 1. Alur dimulai dari pengumpulan data, prapemrosesan, pelabelan, pembagian data, pelatihan model, kalibrasi, evaluasi, hingga penerapan pada seluruh komentar. Setiap tahap dirancang agar dapat diproduksi ulang, yaitu keluarannya bersifat tetap untuk masukan yang sama.




Gambar 1. Diagram alir tahapan penelitian

2.1 Pengumpulan Data

Data berupa 38.845 komentar dari sebelas unggahan Instagram yang membahas kasus pengadaan Chromebook. Data dikumpulkan melalui proses *crawling*, kemudian dianonimkan dengan tidak menampilkan identitas akun pada seluruh proses analisis. Setiap komentar menyimpan atribut waktu, jumlah suka, dan teks. Rentang waktu komentar terbagi ke dalam empat fase peristiwa, yaitu penyelidikan awal, babak pemeriksaan, penahanan, serta tuntutan dan vonis.

2.2 Prapemrosesan

Data mentah memuat sejumlah persoalan teknis. Nilai waktu ditulis dengan koma tanpa tanda kutip, misalnya 30/6/2026, 21.43.41, sehingga setiap baris memiliki satu kolom tambahan yang tidak sesuai dengan header. Oleh karena itu, pembacaan dilakukan baris demi baris dengan memeriksa jumlah kolom, pola tanggal, dan pola jam. Baris yang tidak lolos pemeriksaan dicatat sebagai anomali dan proses dihentikan agar tidak menghasilkan anomali data yang tidak terdeteksi. Alur prapemrosesan selengkapnya ditunjukkan pada Gambar 2.



Gambar 2. Diagram alir prapemrosesan data

Normalisasi teks dilakukan melalui fungsi pembersihan yang menerapkan normalisasi Unicode NFKC, membuang karakter kontrol, dan merapikan spasi ganda. Normalisasi NFKC penting karena sebagian komentar, terutama komentar berpola promosi, memakai huruf gaya khusus untuk menghindari penyaringan. Emoji sengaja dipertahankan karena sekitar 11 persen komentar hanya berisi emoji dan emoji tersebut merupakan sinyal emosi, bukan derau. Contoh perubahan teks sebelum dan sesudah pembersihan disajikan pada Tabel 1.

Tabel 1. Contoh teks sebelum dan sesudah prapemrosesan

Teks mentah	Teks bersih	Alasan
rezim ² yg menyengsarakan	rezim2 yg menyengsarakan	pelipatan karakter superskrip oleh NFKC
KEADILAN SOSIAL. Alah omong kosong	KEADILAN SOSIAL. Alah omong kosong	perapihan spasi ganda
gara P U L A y777.	garaPULAu777.	komentar promosi judi; NFKC menyingkap nama situs yang disamarkan huruf gaya khusus

Selanjutnya komentar *near-duplicate* dikelompokkan menggunakan kunci penyeragaman yang menyamakan varian yang hanya berbeda kapitalisasi, angka, tanda baca, atau huruf gaya khusus. Sebagai contoh, komentar Korban politik dan KORBAN POLITIK dipetakan ke kunci yang sama, yaitu korbanpolitik. Dari 38.845 komentar terbentuk 31.405 kluster, dan 8.474 baris berada dalam kluster yang beranggotakan lebih dari satu. Pengelompokan ini menjadi dasar pembagian

data agar komentar yang nyaris identik tidak tersebar ke data latih dan data uji sekaligus.

2.3 Skema Label dan Pelabelan

Label disusun dalam tiga lapis. Lapis *spam* menandai komentar promosi atau judi daring yang dikeluarkan dari statistik. Lapis sikap terdiri atas enam kelas, yaitu mendukung Nadiem, menentang Nadiem, kritik peradilan, kritik pemerintah, netral atau informasi, dan tak jelas. Lapis emosi terdiri atas lima kelas, yaitu marah, duka, sinis, harapan, dan netral. Prinsip pelabelan adalah mengodekan target yang tertulis secara eksplisit, bukan menebak posisi politik penulis. Untuk komentar yang hanya berisi emoji, emosi ditentukan melalui aturan pemetaan emoji yang bersifat pasti, misalnya emoji menangis dipetakan ke duka, emoji marah ke marah, emoji tertawa ke sinis, dan emoji berdoa ke harapan.

Sebanyak 710 komentar dilabeli manusia mengikuti pedoman pelabelan dan digunakan sebagai acuan evaluasi. Selain itu, 5.912 komentar dilabeli oleh *Large Language Model* (LLM) lokal dengan pedoman yang sama untuk memperbanyak data latih. Data berlabel manusia disebut data *gold*, sedangkan data berlabel LLM disebut data *silver*. Pemisahan ini penting karena klaim kinerja harus bertumpu pada label yang tepercaya, sementara data *silver* hanya berperan sebagai penambah data latih.

Model yang dipakai untuk menghasilkan label *silver* adalah sebuah *Large Language Model* lokal berukuran sekitar sembilan miliar parameter (ornith-1.0-9B) yang dijalankan melalui Ollama pada GPU. Pelabelan dilakukan secara *zero-shot*,


yaitu tanpa contoh berlabel di dalam prompt. Model diberi pedoman pelabelan yang identik dengan yang dipakai anotator manusia sebagai *system prompt*, keluaran dibatasi berformat JSON agar langsung dapat diurai, dan mode penalaran (*thinking*) dinonaktifkan supaya hasilnya deterministik. Komentar yang gagal diurai menjadi JSON dibuang dan tidak ditebak.

2.4 Pembagian Data

Pembagian data dilakukan berbasis kluster *near-duplicate*, bukan berbasis baris, sehingga komentar yang nyaris identik tidak melintasi batas antara data latih dan data uji. Data validasi dan data uji hanya diambil dari data *gold*. Hasil pembagian menghasilkan 6.233 data latih, yang terdiri atas 321 komentar *gold* dan 5.912 komentar *silver*, 106 data validasi, dan 283 data uji.

2.5 Pemodelan

Dua model dibandingkan. Model pertama adalah *baseline* TF-IDF dengan regresi logistik. Ekstraksi fitur menggunakan n-gram karakter agar tahan terhadap salah ketik dan slang, dan bobot kelas diseimbangkan untuk menangani ketidakseimbangan. Model kedua adalah IndoBERT multitugas. Arsitekturnya memakai satu *encoder* IndoBERT (indobert-base-p1) yang dibagi ke tiga lapisan klasifikasi untuk *spam*, sikap, dan emosi seperti pada Gambar 3. Representasi kalimat diperoleh melalui *mean-pooling* atas token yang valid, kemudian tiap lapisan menghasilkan probabilitas kelas. Berbagi satu *encoder* membuat model lebih ringkas dan memungkinkan sinyal antartugas saling menguatkan [13].



Keluaran tiap kepala diubah menjadi probabilitas dengan softmax dan penskalaan suhu (kalibrasi).

Gambar 3. Arsitektur model IndoBERT multitugas

Pelatihan menggunakan fungsi galat *cross-entropy* dengan bobot invers frekuensi kelas untuk mengurangi dominasi kelas mayoritas. Contoh berlabel *silver* diberi bobot lebih rendah, yaitu 0,4, karena labelnya mengandung lebih banyak derau (*noise*) dibanding label manusia. Pendekatan pembobotan ini menjadi alternatif

dari penyeimbangan berbasis pembuatan sampel sintesis seperti SMOTE [15], dan cocok untuk model berbasis Transformer yang bekerja pada representasi token, bukan pada vektor fitur tetap. Optimasi memakai AdamW dengan laju belajar 0,00002 selama enam *epoch*, dan

bobot terbaik dipilih berdasarkan *macro-F1* tugas sikap pada data validasi.

Setelah pelatihan, keyakinan model dikalibrasi dengan penskalaan suhu, yaitu mencari satu nilai suhu yang meminimalkan galat pada data validasi agar probabilitas keluaran lebih merepresentasikan tingkat keyakinan (*confidence*) yang sebenarnya [16]. Selanjutnya ditetapkan ambang abstain per tugas, yaitu ambang keyakinan minimal agar akurasi bagian yang dijawab mencapai paling sedikit 80 persen. Komentar dengan keyakinan di bawah ambang ditandai sebagai ragu, bukan dipaksa ditebak. Nilai suhu hasil kalibrasi adalah 1,52 untuk sikap dan 1,18 untuk emosi, dengan ambang abstain 0,62 untuk sikap dan 0,64 untuk emosi.

2.6 Metrik Evaluasi

Metrik utama adalah *macro-F1*, yaitu rata-rata F1 seluruh kelas dengan bobot yang sama, karena metrik ini tidak bias terhadap kelas mayoritas pada data yang timpang [17]. Selain *macro-F1*, dilaporkan pula akurasi, F1 per kelas, dan jumlah sampel (*support*) tiap kelas. Evaluasi dilakukan pada 283 komentar uji berlabel manusia. Sebagai pembanding tambahan disertakan *baseline* mayoritas, yaitu prediktor yang selalu memilih kelas terbanyak.

3. Hasil dan Pembahasan

Distribusi jumlah data pada setiap tahap disajikan pada Tabel 2. Dari 38.845 komentar, sebanyak 0,5 persen atau 203 komentar terdeteksi sebagai *spam* dan dikeluarkan dari statistik sentimen. Volume komentar tidak merata antarfase, dengan puncak pada fase tuntutan dan vonis sebanyak 29.704 komentar.

Tabel 2. Distribusi jumlah data

Bagian	Jumlah
Total komentar	38.845
Klaster <i>near-duplicate</i>	31.405
Data <i>gold</i> (berlabel manusia)	710
Data <i>silver</i> (berlabel model)	5.912
Data latih	6.233
Data validasi	106
Data uji	283

Perbandingan kinerja keempat model pada data uji disajikan pada Tabel 3. Baseline mayoritas memperoleh *macro-F1* yang sangat rendah pada sikap dan emosi, yaitu 0,066 dan 0,072, yang menegaskan bahwa akurasi tinggi

pada kelas mayoritas tidak mencerminkan kemampuan klasifikasi yang sebenarnya. IndoBERT multitugas memperoleh *macro-F1* tertinggi di antara model yang dilatih pada tugas sikap dan emosi, yaitu 0,544 dan 0,624, sedikit di atas *baseline* TF-IDF. Selisih yang tipis ini menunjukkan bahwa dengan data *gold* yang terbatas, *baseline* klasik masih sangat kompetitif, sehingga klaim keunggulan model pralatih harus diuji terhadap *baseline* yang kuat.

Tabel 3. Perbandingan *macro-F1* antarmodel pada data uji

Model	Sikap	Emosi	Spam
Baseline mayoritas	0,066	0,072	0,487
TF-IDF + regresi logistik	0,534	0,616	1,000
IndoBERT multitugas	0,544	0,624	1,000
Anotator LLM	0,548	0,638	0,982

Kinerja per kelas untuk tugas sikap disajikan pada Tabel 4. Model paling andal pada kelas kritik peradilan dengan F1 sebesar 0,809 dan pada kelas tak jelas dengan F1 sebesar 0,745. Sebaliknya, kelas netral atau informasi dan menentang Nadiem memperoleh F1 rendah karena jumlah sampelnya kecil, yaitu 7 dan 18. Pola ini wajar pada data yang timpang dan menegaskan bahwa penambahan sampel berlabel manusia pada kelas minoritas diperlukan untuk meningkatkan kinerja.

Tabel 4. F1 per kelas tugas sikap (IndoBERT multitugas)

Kelas sikap	F1	Jumlah sampel
Mendukung Nadiem	0,649	70
Menentang Nadiem	0,324	18
Kritik peradilan	0,809	78
Kritik pemerintah	0,537	42
Netral atau informasi	0,200	7
Tak jelas	0,745	68
<i>macro-F1</i>	0,544	akurasi 0,650

Model IndoBERT multitugas kemudian dipakai untuk menyekor seluruh 38.845 komentar. Komposisi sikap dan emosi pada komentar non-*spam* disajikan pada Tabel 5. Kelas sikap terbesar adalah tak jelas sebesar 26,5 persen, diikuti mendukung Nadiem 25,1 persen dan kritik peradilan 22,8 persen. Besarnya kelas tak jelas berkaitan dengan banyaknya komentar yang ambigu, sarkastik, atau bercampur bahasa, yang memang menyulitkan pelabelan. Pada dimensi emosi, duka dan marah mendominasi


dengan total mendekati 60 persen, sedangkan harapan hanya 8,2 persen.

Tabel 5. Komposisi sikap dan emosi komentar non-spam

Sikap	Persen	Emosi	Persen
Tak jelas	26,5	Duka	30,1
Mendukung Nadiem	25,1	Marah	29,6
Kritik peradilan	22,8	Sinis	21,2
Menentang Nadiem	17,0	Netral	10,9
Kritik pemerintah	6,7	Harapan	8,2
Netral atau informasi	1,9		

Analisis antarfase menunjukkan pergeseran fokus percakapan, seperti divisualisasikan pada

Gambar 4. Pada fase awal, kritik peradilan hanya 5,3 persen, sedangkan pada fase tuntutan dan vonis kritik ini meningkat tajam menjadi 27,3 persen. Peningkatan tersebut mencerminkan reaksi publik atas berat atau janggalnya vonis serta isu kenaikan gaji hakim yang beredar. Temuan lain, pada seribu komentar dengan jumlah suka tertinggi, proporsi sikap mendukung Nadiem naik menjadi 30,2 persen dari 25,1 persen pada keseluruhan data. Hal ini menunjukkan komentar yang paling disukai cenderung lebih mendukung, sehingga popularitas komentar tidak dapat dianggap mewakili proporsi keseluruhan percakapan.




Gambar 4. Pergeseran komposisi sikap antarfase (persentase tiap fase)

Secara keseluruhan, hasil ini menegaskan bahwa wacana kasus tidak sekadar pro atau kontra terhadap satu orang, melainkan tersebar ke lembaga peradilan dan pemerintah. Skema multitugas terbukti mampu memisahkan dimensi sikap dan emosi sekaligus, yang tidak tertangkap jika sentimen hanya diperlakukan sebagai polaritas tunggal. Sejalan dengan studi terdahulu pada kasus Nadiem yang memakai SVM [7], penelitian ini memperluas cakupan dengan menambahkan dimensi emosi dan target yang lebih beragam.

3.1 Implementasi Aplikasi

Hasil penyekoran disajikan melalui aplikasi web berbasis Streamlit agar temuan dapat ditelusuri secara interaktif. Aplikasi menyediakan halaman ringkasan, eksplorasi kata dan komentar, tren antarfase, sub-isu dan target, serta halaman untuk mencoba model pada teks baru. Tampilan utama aplikasi ditunjukkan pada Gambar 5. Komentar yang membuat model ragu ditandai secara eksplisit, dan komentar *spam* dikecualikan dari statistik secara bawaan.



Gambar 5. Tampilan utama aplikasi web (halaman Ringkasan)

Untuk mendukung reproduktibilitas, seluruh data, kode, model, dan aplikasi tersedia secara terbuka pada tautan berikut.

- Dataset (Kaggle): <https://www.kaggle.com/datasets/iredragonicy/nadiem-chromebook-instagram-comments>
- Kode program (GitHub): <https://github.com/IRedDragonICY/sentimen-chromebook-nadiem>
- Model terlatih (Hugging Face): <https://huggingface.co/IRedDragonICY/indobert-sentimen-chromebook>
- Aplikasi daring (Streamlit): <https://sentimen-nadiem.streamlit.app>

3.2 Keterbatasan

Penelitian ini memiliki sejumlah keterbatasan. Data berasal dari sebelas unggahan Instagram sehingga bukan sampel acak yang mewakili opini publik nasional dan hasilnya tidak boleh digeneralisasi. Selain itu, sarkasme dan sindiran halus tetap sulit diklasifikasikan, sebagaimana tercermin pada besarnya kelas tak jelas. Jumlah data berlabel manusia yang terbatas juga membatasi kinerja pada kelas minoritas. Sistem ini mengukur sentimen komentar, bukan menilai bersalah atau tidaknya pihak mana pun, dan menjunjung asas praduga tak bersalah.

4. Kesimpulan

Penelitian ini membangun analisis sentimen multitugas atas 38.845 komentar Instagram pada kasus dugaan korupsi pengadaan Chromebook. Melalui pipeline yang menangani teks kotor dan

komentar *near-duplicate*, skema label tiga lapis, serta model IndoBERT multitugas, sistem mampu memprediksi *spam*, sikap, dan emosi secara serentak. Model IndoBERT multitugas memperoleh *macro-F1* sebesar 0,544 pada sikap dan 0,624 pada emosi, sedikit mengungguli *baseline* TF-IDF, yang menunjukkan bahwa pada data *gold* terbatas keunggulan model pralatih belum besar dan *baseline* klasik masih kompetitif. Analisis komposisi memperlihatkan kritik terhadap lembaga peradilan cukup menonjol dan menguat pada fase vonis, sementara emosi didominasi duka dan marah. Penelitian lanjutan disarankan menambah jumlah komentar berlabel manusia terutama pada kelas minoritas, mencoba *encoder* Indonesia lain, dan menguji strategi penanganan sarkasme untuk menekan proporsi kelas tak jelas.

Daftar Pustaka

- [1] N. D. Putranti dan E. Winarko, "Analisis Sentimen Twitter untuk Teks Berbahasa Indonesia dengan Maximum Entropy dan Support Vector Machine," *IJCCS (Indonesian Journal of Computing and Cybernetics Systems)*, vol. 8, no. 1, hlm. 91-100, 2014.
- [2] N. Fitriyah, B. Warsito, dan D. A. I. Maruddani, "Analisis Sentimen Gojek pada Media Sosial Twitter dengan Klasifikasi Support Vector Machine (SVM)," *Jurnal Gaussian*, vol. 9, no. 3, hlm. 376-390, 2020.
- [3] J. E. B. Sinulingga dan H. C. K. Sitorus, "Analisis Sentimen Opini Masyarakat terhadap Film Horor Indonesia Menggunakan Metode SVM dan TF-IDF," *Jurnal Manajemen Informatika (JAMIKA)*, vol. 14, no. 1, hlm. 42-53, 2024.

- [4] A. Setiawan dan R. R. Suryono, "Analisis Sentimen Ibu Kota Nusantara menggunakan Algoritma Support Vector Machine dan Naive Bayes," *Edumatic: Jurnal Pendidikan Informatika*, vol. 8, no. 1, hlm. 183-192, 2024.
- [5] D. Pramudita, Y. Akbar, dan T. Wahyudi, "Analisis Sentimen terhadap Program Kartu Indonesia Pintar Kuliah pada Media Sosial X Menggunakan Algoritma Naive Bayes," *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, vol. 4, no. 4, hlm. 1420-1430, 2024.
- [6] M. Khadapi dan V. M. Pakpahan, "Analisis Sentimen Berbasis Jaringan LSTM dan BERT terhadap Diskusi Twitter tentang Pemilu 2024," *JUKI: Jurnal Komputer dan Informatika*, vol. 6, no. 2, hlm. 130-137, 2024.
- [7] S. R. Putri, M. Arifin, dan Supriyono, "Analisis Sentimen Publik terhadap Nadiem Makarim sebagai Mendikbudristek menggunakan Support Vector Machine (SVM)," *Jurnal Sistemasi*, 2025.
- [8] J. Devlin, M.-W. Chang, K. Lee, dan K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," dalam *Proceedings of NAACL-HLT*, hlm. 4171-4186, 2019.
- [9] A. Vaswani dkk., "Attention Is All You Need," dalam *Advances in Neural Information Processing Systems* 30, hlm. 5998-6008, 2017.
- [10] B. Wilie dkk., "IndoNLU: Benchmark and Resources for Evaluating Indonesian Natural Language Understanding," dalam *Proceedings of the 1st ACL-IJCNLP*, hlm. 843-857, 2020.
- [11] F. Koto, A. Rahimi, J. H. Lau, dan T. Baldwin, "IndoLEM and IndoBERT: A Benchmark Dataset and Pre-trained Language Model for Indonesian NLP," dalam *Proceedings of the 28th COLING*, hlm. 757-770, 2020.
- [12] A. Purwarianti dan I. A. P. A. Crisdayanti, "Improving Bi-LSTM Performance for Indonesian Sentiment Analysis Using Word2Vec and Language Model," dalam *Proc. International Conference on Advanced Informatics: Concepts, Theory and Applications (ICAICTA)*, 2019.
- [13] S. Ruder, "An Overview of Multi-Task Learning in Deep Neural Networks," *arXiv preprint arXiv:1706.05098*, 2017.
- [14] F. Koto dan G. Y. Rahmaningtyas, "InSet Lexicon: Evaluation of a Word List for Indonesian Sentiment Analysis in Microblogs," dalam *Proc. International Conference on Asian Language Processing (IALP)*, hlm. 391-394, 2017.
- [15] N. V. Chawla, K. W. Bowyer, L. O. Hall, dan W. P. Kegelmeyer, "SMOTE: Synthetic Minority Over-sampling Technique," *Journal of Artificial Intelligence Research*, vol. 16, hlm. 321-357, 2002.
- [16] C. Guo, G. Pleiss, Y. Sun, dan K. Q. Weinberger, "On Calibration of Modern Neural Networks," dalam *Proceedings of the 34th International Conference on Machine Learning (ICML)*, hlm. 1321-1330, 2017.
- [17] M. Sokolova dan G. Lapalme, "A Systematic Analysis of Performance Measures for Classification Tasks," *Information Processing and Management*, vol. 45, no. 4, hlm. 427-437, 2009.